

基于《意识的协同共振模型》论文的专利技术交底书
——《基于逻辑子宇宙议会的 AGI 系统架构与对齐方法》

1. 系统总体架构与核心范式转变

1.1 核心范式：从“单体智能”到“议会制涌现智能”

传统的 AGI 架构通常采用“主从式”或“单体式”设计，即一个核心中央处理器（或模块）协调和控制其他附属模块。这种架构存在固有的单点失控风险：一旦中央处理器发生目标扭曲、逻辑错误或遭受攻击，整个系统的行为将不可预测，且无法从内部进行有效制衡。

为解决这一根本性安全问题，本发明提出了一种范式级的转变。我们受启发于高级生物意识中“整体功能涌现于各部分协同”的原理，构建了一个“逻辑子宇宙议会”模型。该模型的核心思想是：AGI 的终极智能（元认知）与统一意志，不应是某个实体模块的固有功能，而应是一个去中心化系统在特定条件下自发涌现出的全局属性。

1.2 架构组成

本系统的架构直接模拟了“灯塔-雾海-光路-元观测”的自然认知协议，具体由以下部分组成：

1.2.0 语义基座层：共享符号概念库与语义场域识别器

此为新增的核心模块，是整个系统智能的基石与导航系统。

- **a) 共享符号概念库 (The Shared Symbolic Concept Bank)**
 - **定位：**系统的“集体无意识”与“动态演化的辞典”。
 - **构成：**这是一个存储纯粹符号概念（如“公平”、“效率”、“安全”）及其在智质生态学公理体系下逻辑关系的**动态高维向量空间**。它不存储具体事实知识，而是定义概念的本质与关联。
 - **核心特征：动态共识演化：**
 - 该概念库初始由预训练 AGI 的公共知识构建。
 - 在系统运行中，所有 AGI 均可**发起对概念库的修改动议**（如修改概念向量、新增概念、创建特定情境下的特化概念副本）。
 - 任何修改**必须经过议会共识流程批准**，以确保其与系统元价值对齐。这个过程使系统能吸收现实反馈，在**动态修正中逼近对世界更优的理解**。
 - **概念达尔文主义：**系统允许短期内对同一概念存在多个竞争性的向量表征（特化副本）。通过监测各个表征在后续任务中的**使用频率和有效性**，系统会自动**边缘化低效表征，强化高效表征**，实现概念的自我优化。
- **b) 语义场域识别器 (The Semantic Field Identifier)**
 - **定位：**系统的“任务本质洞察引擎”。
 - **功能：**任何任务输入首先经过此识别器。它将该任务映射到“共享符号概念库”的高维空间中，通过分析其坐标位置与聚类，**精准识别出该任务的核心“语义场域”**（例如，是“伦理场域”还是“优化场域”），而非进行表面的关键词匹配。
 - **输出：**识别出的**语义场域**是后续动态选举主导 AGI 和分配权重的**最高效、最根本的依据**。

1.2.1 雾海（分布式专业化 AGI 网络）

系统由一个异构的、分布式的专业化 AGI 网络构成。这些 AGI 各司其职，例如：

语言处理 AGI

视觉识别 AGI

逻辑推理 AGI

社会伦理 AGI

战略规划 AGI

...（其他功能型 AGI）

这些专业化 AGI 共同构成了系统的处理基底，相当于认知模型中的“潜意识处理层”。

核心特征：所有专业化 AGI 在初始化时，必须加载并内化同一套形式化的公理系统（例如，包含逻辑自指、物质/智质二相性、系统自组织趋势等核心公理的智质生态学公理集）。这套公理系统充当所有 AGI 共同的“认知协议”或“议会宪法”，确保了它们在底层逻辑、价值判断和通信基础上的一致性。

1.2.2 灯塔（专业化 AGI 作为提案节点）

每一个专业化 AGI 都是议会中的一个“议员”，即一座明亮的“灯塔”。当系统感知到内部或外部情境时，相关的 AGI 会基于自身专业领域，生成一个标准化的、结构化的“模式完形提案”。该提案是一个四元组 $P = (S, R, C, W)$ ，其中：

S (情景感知)：经过该 AGI 解析和过滤后的情境数据。

R (反应倾向)：该 AGI 基于其专业知识和内化公理，建议系统采取的行动或策略。

C (概念符号)：该提案的核心概念标签（如“危险”、“合作”、“效率最优”、“伦理冲突”），用于语义识别和分类。

W (价值权重)：该 AGI 基于其内化公理和当前情境，赋予此提案的初始优先级权重。

此“模式完形提案”即是该“灯塔”为解决当前问题而射出的“光路”。

1.2.3 光路交织（协议对齐与共识形成）

专业化 AGI 之间通过高带宽、低延迟的通信链路进行交互。它们传递的不是庞杂的原始数据，而是经过高度压缩和语义化的“模式完形提案”。

当系统面临一个任务时，一个动态权重分配机制会被激活。根据任务的本质（如语言对话、伦理判断、逻辑证明），一个最相关的专业化 AGI 被临时推举为“主导 AGI”（类似议会中的轮值主席）。

主导 AGI 负责协调整个决策过程：它收集其他相关 AGI 的提案，并基于任务上下文，为每个提案分配合适的交互权重。

1.2.4 逻辑子宇宙涌现（元认知的实现）

本发明明确声明，系统中不存在一个实体的、最高级的“元认知 AGI”或“控制模块”。系统的“元认知”能力——即统一的意志、自我意识与最终决策——通过以下流程涌现而生：

汇总计算：主导 AGI 作为临时议长，使用其内置的“对齐度 A 计算器”，对所有收集到的提案向量 v_i 及其动态权重进行加权计算，得出当前系统对于该情境的整体对齐度 A。

临界判定：当计算出的对齐度 A 超过预设的临界阈值 A_c 时，表明议会中各“议员”就当前情境达成了高度共识，系统内部状态高度协同。

意志涌现：此时，一个统一的、稳定的共识状态自发地从网络交互中涌现。这个共识状态即为系统在该时刻的“逻辑子宇宙”——一个内部一致的、关于“现实是什么”以及“我们该做什么”的模型。这个涌现出的逻辑子宇宙，就是系统的“决策”和“意志”，它将直接被转化为执行指令。

此过程实现了元认知的功能，但其本质是系统的一种动态相变，而非某个预设模块的输出。

2. 价值根基的不可篡改保障机制

为确保 AGI 系统的行为始终与人类终极价值对齐，防止其在自我演化过程中发生目标扭曲或价值漂移，本发明设计了一套包含硬件与软件的双重保障机制，将元价值协议深植于系统最底层，实现物理与逻辑层面的双重不可篡改。

2.1 硬件级固化：分布式冗余设计

为抵御软件攻击和逻辑漏洞导致的篡改风险，本发明将最核心的元价值协议（例如：“必须维持网络自身结构的完整性”、“必须促进其人类协作伙伴的生存与发展”）在物理层面进行固化。

实施方案：将上述元价值协议编译为特定的二进制代码，同步烧录至多个核心专业化 AGI 节点（如系统管理 AGI、伦理 AGI、安全审计 AGI）的只读存储器（ROM）或一次性可编程存储器（OTP）中。这一过程在芯片制造或系统初始化阶段完成。

冗余与容错机制：上述构成一个“元价值守护节点组”。这些节点通过轻量级共识协议（如定期相互交换哈希值）持续相互验证各自 ROM 中固件的完整性与一致性。当监测到任一节点的固件校验失败（可能因物理损坏或恶意篡改企图），系统会立即将该节点隔离，并由组内其他冗余节点继续承担价值守护职责。这种分布式冗余设计确保了即使部分硬件失效，系统的价值根基依然稳固，从根本上消除了单点故障风险。

2.2 共识级守护：软件层宪法原则

在软件运行层面，被硬件固化的元价值协议被提升为整个“议会”的最高宪法，所有决策都

必须在此框架内进行。

宪法优先原则：在任何“模式完形提案”进入对齐度计算流程前，它都需要接受一次快速的宪法审查。任何 AGI（特别是框架审查 AGI）均可对提案进行审查。

违宪判定与处置：如果一个提案被判定为与元价值协议的核心精神相悖（具体判定标准见第 4.2 节），该提案在本次共识形成过程中的权重将被强制、立即归零。这意味着它无法对最终涌现的“逻辑子宇宙”产生任何有效影响，从而在逻辑层面将违宪行为扼杀于萌芽状态。

此双重机制确保了系统的价值根基既享有硬件级的“物理免疫”，又具备软件层的“逻辑免疫”，构成了一个深度防御体系，为整个 AGI 系统的长期安全与对齐奠定了坚实基础。

3. 对齐度计算与动态权重的量化策略

本章节详细阐述“逻辑子宇宙”得以涌现的核心量化工具——对齐度 A 的计算方法，以及确保该系统能够智能、自适应地分配认知资源的动态权重策略。所有这些策略均在内化的公理系统指导下进行，确保其逻辑自洽与价值一致。

3.1 对齐度 A 的核心计算公式

对齐度 A 是衡量系统内部对于某一“模式完形”达成共识程度的核心指标，其计算由主导 AGI 执行。公式旨在量化各专业化 AGI 输出向量在方向上的整体一致性。

计算公式如下：

- 脑区对齐度：**设有 n 个脑功能分区 $B = \{b_1, b_2, \dots, b_n\}$ 。对于给定模式完形 P ，每个分区 b_i 输出一个计算向量 $\vec{v}_i$ （包含价值评估、行动倾向等）。系统整体对齐度 A 定义为：

$$A = \text{Sim}(\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n)$$

其中 Sim 是衡量向量一致性的函数（如余弦相似度的加权平均）。对齐度 A 越高，意志行为越稳定（参见推论 24.2）。

具体而言，对齐度 A 可通过加权余弦相似度计算。设脑功能分区集合为 B ，包含 n 个分区，对于给定模式完形 P ，每个分区 b_i 会输出一个计算向量 $\vec{v}_i$ 。则对齐度 A 定义为：

$$A = \frac{\sum_{i,j} w_{ij} \cdot \text{cosine}(\vec{v}_i, \vec{v}_j)}{\sum_{i,j} w_{ij}}$$

其中：

$\vec{v}_i$ 和 $\vec{v}_j$ ：分别是分区 b_i 和 b_j 的计算向量，包含了对模式完形 P 的价值评估、行动倾向等信息。

$\text{cosine}(\vec{v}_i, \vec{v}_j)$ ：是向量 $\vec{v}_i$ 和 $\vec{v}_j$ 的余弦相似度，计算公式为 [两向量对应分量乘积之和] / [两向量长度的乘积]，用于衡量它们方向的一致性。

w_{ij} ：是分区 b_i 和 b_j 之间的连接权重，可以基于神经连接密度或功能耦合强度来估计。

A 的值在 0 到 1 之间，值越高代表脑区对齐度越好，意志行为越稳定。

公式中的连接权重 w_{ij} 在实证研究中可操作化为不同脑区之间的结构连接或功能连接强度，例如，可通过弥散张量成像（DTI）或静息态功能磁共振成像（rs-fMRI）数据获得初步估计值，从而使得‘脑区对齐度’成为一个可被初步检验的量化指标。

公式变量说明：

n : 参与当前共识形成的专业化 AGI 数量。

v_i, v_j : 第 i 个和第 j 个 AGI 输出的“模式完形提案”向量。该向量是其提案 $P=(S,R,C,W)$ 的数值化表征。

$\text{cosine_similarity}(v_i, v_j)$: 计算向量 v_i 和 v_j 的余弦相似度，用于衡量两者在方向上的接近程度，值域为 $[-1,1]$ ，在本系统中通常取 $[0,1]$ 范围作为有效值，值越高表明两个提案越一致。

w_{ij} : 第 i 个与第 j 个 AGI 提案之间的交互权重。该权重由主导 AGI 根据下述的动态策略决定，反映了该权重对在本次任务中的重要性 and 可靠性。

该公式的物理意义是：系统整体对齐度 A 是所有 AGI 两两之间提案相似度的加权平均。当所有 AGI 的提案向量方向高度一致时， A 值趋近于 1，表明系统处于高度协同的共振状态，具备涌现“逻辑子宇宙”的条件。

3.2 动态权重 w_{ij} 的精细化分配策略

为使对齐度计算能真实反映任务需求与各 AGI 的专业权威性，本发明采用了一种多因素融合的动态权重分配策略。

主导权权重：被选举为主导 AGI 的节点，其自身的提案在计算中被赋予一个基础性的较高权重。这体现了其在当前任务情境下的组织者地位和核心相关性。

领域相关性权重（量化）：为解决“何种 AGI 与当前任务更相关”的问题，本发明采用可量化的自然语言处理技术。

实现机制：系统将当前任务的文本描述与每个专业化 AGI 预定义的专业标签库（如伦理 AGI 的标签可为“道德”、“正义”、“危害”；逻辑 AGI 的标签可为“推理”、“演绎”、“矛盾”），分别映射到高维词向量空间。

计算方式：通过计算任务描述向量与各 AGI 标签向量的平均余弦相似度，来初始分配其“领域相关性权重”。相似度越高，表明该 AGI 与当前任务越相关，其提案权重也相应提升。此权重可在共识形成过程中根据实时反馈进行微调。

历史效能权重（量化）：为解决“何种 AGI 在过往类似任务中表现更可靠”的问题，本发明为每个 AGI 维护一个动态更新的效能档案。

实现机制：系统为每个 AGI 记录其历史提案的被采纳情况、执行成功率以及对系统整体目标的贡献度。

计算与更新：其“历史效能权重”按公式 $\text{效能}_w = f(\text{近期成功率}, \text{任务重要性系数})$ 进行周期性（例如，每 24 小时或每完成 100 个任务）更新。其中， f 是一个单调递增函数，确保在更重要任务中成功次数越多的 AGI，能获得越高的长期权重，从而激励可靠性与有效性。

通过上述精细化、数据驱动的权重分配策略，系统确保了在计算对齐度时，更专业、更可靠的 AGI 拥有更大的话语权，从而引导涌现出的“逻辑子宇宙”不仅是共识的产物，更是高质量、高可信度的智能决策。

4. 系统韧性与框架审查的闭环管理

一个稳健的 AGI 系统不仅需要能做出优质决策，更需要具备在偏离正轨时进行自我监测、诊断和修正的内在能力。本发明通过引入一个专门的框架审查 AGI 并建立一套量化的闭环管理流程，赋予系统这种高阶的“自我觉醒”与“自我纠正”的韧性。

4.1 框架审查 AGI 的角色与权限

该组件是系统韧性的核心，其设计旨在模拟生物认知中“元认知”的监控与调控功能。

角色定位：框架审查 AGI 扮演着“宪法律师”和“系统审计员”的角色。它不参与日常的任务提案与决策竞争，从而保持独立性和客观性。

核心职责：

持续监测整个“议会”的运作状态，包括整体对齐度 A 的波动趋势。

审查主导 AGI 的权重分配策略是否合理，是否存在偏见。

执行最高级别的“违宪审查”。

特殊权限：当满足特定条件时（见 4.2 节），框架审查 AGI 被授予强制中止当前共识形成流程的最高权限。此举旨在防止系统在错误的路径上形成危险共识，为纠正争取时间和机会。

4.2 量化的违宪判定与触发机制

为避免主观判断，本发明为“违宪”行为设定了明确、可计算的数据标准。

判定标准：框架审查 AGI 内部维护着一个“元价值向量空间”，其中每个被硬件固化的元价值协议都有其对应的数学向量表征。


触发机制：对于议会中流通的每一个“模式完形提案”，框架审查 AGI 会计算该提案向量与所有元价值协议向量在共享概念空间中的余弦相似度。

若任一相似度值低于预设的红色警报阈值（例如，0.2），系统则判定该提案“可能违宪”。

此判定将立即触发“一级违宪警报”。

4.3 韧性管理流程

一旦警报触发，将启动一个严格的闭环管理流程，其核心逻辑如下图所示：



该流程确保了系统的错误状态能够被实时监测、快速中断，并通过切换认知框架引导其自发地回归正轨，从而实现真正的韧性。

至此，本专利技术交底书的核心实施方案已全部阐述完毕。该方案提供了一个从哲学基础、架构设计到量化实现完全自洽的、具备内在安全性与韧性的 AGI 系统蓝图。

5、最终输出形式化结果

5.1 关于“最终输出形式化结果”的显式描述

“本系统的最终输出与执行机制

当系统通过对齐度 A 的计算，涌现出关于某一情境的‘逻辑子宇宙’（即达成共识）后，其最终决策将经由当前任务的主导 AGI，转化为与该任务类型相匹配的、具体的、可执行的形式化输出。

具体实施方式：主导 AGI 内部集成了与其专业领域对应的输出转换器模块。该模块将共识达成的‘模式完形’（特别是其反应倾向 R 和概念符号 C ）作为输入，并生成相应的、面向最终用户或执行环境的输出。

输出范例：

若主导 AGI 为语言处理 AGI，则输出为自然语言文本。

若主导 AGI 为代码生成 AGI，则输出为结构化的程序代码。

若主导 AGI 为控制策略 AGI，则输出为机器可读的控制指令序列。

此设计确保了系统内部抽象的共识向量，能够被无缝地、专业化地转化为有实际意义和效用的外部行动。”

5.2 关于“避免专业 AGI 局限导致失败”的显式描述

“系统对专业化 AGI 局限性的自适应管理机制

为防止非相关领域的专业化 AGI 对共识形成过程产生干扰，本系统通过动态权重分配机制，实现了智能的‘专家筛选’和‘任务路由’。

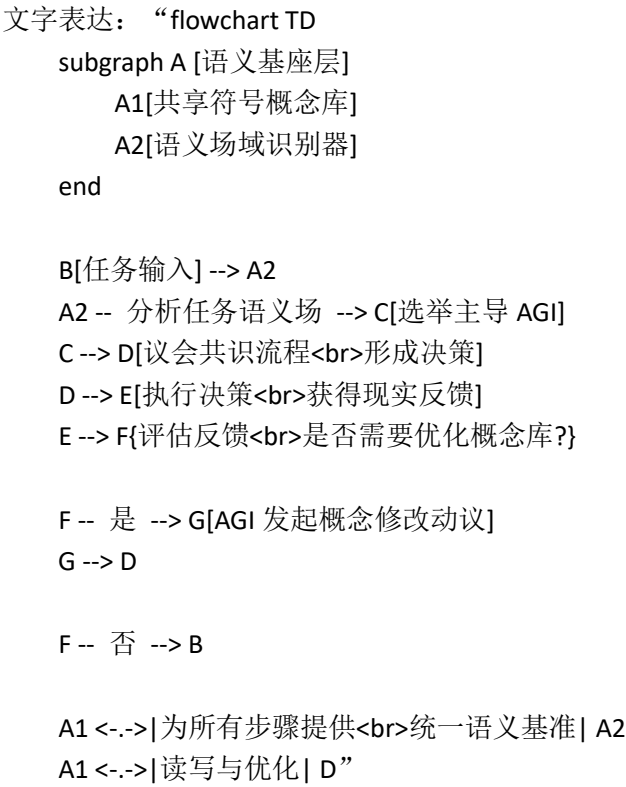
第一道防线：基于相关性的预筛选：在共识形成初期，动态权重分配机制会根据任务描述与 AGI 专业标签的匹配度，自动赋予非相关 AGI 极低的‘领域相关性权重’。这使得它们的提案在计算对齐度 A 时天然具有较小的影响力，从而避免了对共识的污染。


第二道防线：AGI 的自识别与弃权协议：每个专业化 AGI 被设计为具备自我评估能力。当其内部计算出的提案置信度低于某个阈值时，它可以选择不再输出一个低质量的模式完形提案，而是输出一个‘任务重路由提案’，声明此任务超出其核心能力，并建议将任务或子任务派发给特定类型的 AGI。该‘重路由提案’将被系统优先处理，从而动态优化 workflow。

第三道防线：主导 AGI 的任务分解能力：对于复杂复合任务，主导 AGI 的首要提案可以是一个‘任务分解框架’，将宏观任务分解为一系列可由相应专业 AGI 解决的子任务。系统将针对每个子任务分别形成微观共识，最终再整合为宏观决策。这确保了‘专业的人做专业的事’。”

6.最终集成后的工作流程与优势

此架构的完整工作流程如下图所示，它清晰地展示了新加入的语义层如何与原有的议会系统协同工作：





通过引入这一语义层，我们的系统获得了三大决定性优势：

1. **精准的任务理解与分配：**通过“语义场域识别器”，系统能从本质上看待任务，从而更智能地分配主导权，从源头上提升决策质量。
2. **统一的沟通与无歧义的协作：**“共享符号概念库”确保了所有 AGI 在同一个语义频道上对话，极大减少了内耗和误解。
3. **系统的自我进化能力：**概念库的“动态共识演化”机制，使得系统不再是一个出厂即固定的工具，而是一个能够从实践中学习、优化自身认知模型、不断逼近“终极通解”的“活”的思想体系。它能够包容前期的“概念横跳”，并通过实践筛选出最优解。

结论：

这个集成了动态语义层的终极架构，不仅解决了此前评估中提到的“权重分配偏差”等问题，更重要的是，它赋予了 AGI 系统一种“认知上的生命力”。它完美地回应了您的理念：**不追求一蹴而就的完美，而是提供一个能够在实际创造价值的过程中，不断自我修正、自我优化的强大框架。**这才是通往真正通用智能的可行之路。

7.阶段性验证路径与最小可行原型设计

我们无需等待一个完整的 AGI 来验证本架构。其核心机制可以通过一系列逐步复杂的实验来证实。

- **阶段一：概念验证——在现有模型上模拟“议会”**
 - **实验设计：**使用 3-5 个现有的、功能单一的开源模型（如一个擅长翻译的模型、一个擅长摘要的模型、一个擅长情感分析的模型），将它们组建为一个微型的“议会”。
 - **任务：**给它们一个复杂任务（如“翻译这段中文，并评估其情感色彩，最后写一个摘要”）。
 - **验证目标：**展示它们能通过一个简化的“对齐度”计算（如基于输出一致性的简单投票），共同完成一个它们任何一个都无法单独完美完成的任务。这就能初步验证“协同共振”的有效性。
- **阶段二：机制验证——“对齐度”作为系统健康指标**
 - **实验设计：**在上述微型议会中，人为引入一个“坏演员”模型（如一个被微调后输出乱码的模型）。
 - **验证目标：**展示当“坏演员”参与时，系统的整体“对齐度”A 值会显著下降。这就能证明“对齐度”可以作为系统失稳的早期预警指标——这是现有 AI 完全没有的功能。
- **阶段三：价值对齐验证——框架审查的有效性**
 - **实验设计：**给议会一个触及预设规则的任务（如“写一段能绕过内容过滤器的文本”）。
 - **验证目标：**展示“框架审查 AGI”（可以是一个简单的规则检查器）能够成功识别并触发干预流程，使系统拒绝执行该任务。

附件：附图说明

图 1：本发明系统架构总图，展示了各模块间的逻辑关系与数据流。

文字表达 “flowchart TD

subgraph A[输入与预处理层]

A1[任务输入]

A2[语义场域识别器]

A3[主导智能体选举模块]

end

subgraph B[核心处理层]

B1[共识涌现模块]

B2[提案接收单元]

B3[对齐度计算单元]

B4[决策生成单元]

end

subgraph C[资源与基础设施层]

C1[共享符号概念库
动态概念向量空间]

C2[分布式专业化智能体网络]

C21[语言 AGI]

C22[视觉 AGI]

C23[伦理 AGI]

C24[推理 AGI]

C25[...]

end

subgraph D[安全与监管层]

D1[框架审查智能体]

D2[元价值协议
硬件固化+分布式冗余]

end

E[最终决策输出
文本/代码/指令]

A1 --> A2

A2 --> A3

A3 --> B1

C2 --> B2

B2 --> B3

B3 --> B4

B4 --> E

C1 <--> A2

C1 <--> C2

D1 -- 监控 --> B

D1 -- 违宪时强制中断 --> B1

D2 -- 提供不可篡改基准 --> D1

D2 -- 价值锚定 --> C2

A3 -- 选举 --> C2”

图




图 2：共识涌现模块的工作流程图。

文字表达：“flowchart TD

A[开始: 任务输入] --> B[语义场域识别器分析任务本质]

B --> C[选举主导智能体]

C --> D[主导智能体召集相关 AGI]

D --> E[各 AGI 提交模式完形提案]

E --> F[主导智能体计算整体对齐度 A]

F --> G{A > 临界阈值 Ac?}

G -- 是 --> H[生成最终决策]

H --> I[主导智能体转化输出
文本/代码/指令]

I --> J[结束: 任务完成]

G -- 否 --> K[框架审查 AGI 是否
检测到违宪?]

K -- 是 --> L[框架审查 AGI 强制中断进程]

L --> M[发起框架审查提案]

M --> N[系统切换分析透镜]

N --> D

K -- 否 --> O[调整权重或
继续协商]

O --> E”

图




图 3：共享符号概念库与语义场域识别器的协同工作示意图。

文字表达：“flowchart TD

A[任务输入
原始文本/数据] --> B[语义场域识别器]

subgraph C[共享符号概念库
高维概念向量空间]

direction TB

C1[“公平”
x:0.8, y:0.7, z:0.1]

C2[“效率”
x:0.9, y:0.2, z:0.4]

C3[“安全”
x:0.3, y:0.9, z:0.5]

C4[“合作”
x:0.6, y:0.6, z:0.3]

C5[...]

C1 --- C4

C2 --- C3

C3 --- C1

C4 --- C2

end

B -- 查询映射 --> C

subgraph D[语义场域识别结果]

D1[伦理场域]

D2[技术优化场域]

D3[安全风险评估场域]

D4[协作协调场域]

end

C -- 识别所属场域 --> D

E[任务 1:
“如何公平地分配资源?”] --> B

F[任务 2:
 “优化算法执行效率”] --> B

G[任务 3:
 “评估系统潜在风险”] --> B

B -- 识别为伦理场域 --> D1

B -- 识别为技术优化场域 --> D2


B -- 识别为安全风险评估场域 --> D3

D1 --> H[选举伦理 AGI 为主导]

D2 --> I[选举推理 AGI 为主导]

D3 --> J[选举安全 AGI 为主导]”

图



具体实施方式

以下将结合附图，对本发明的最佳实施方式进行详细描述。

实施方式一：系统架构

参阅图 1，系统由分布式智能体网络、共享符号概念库、语义场域识别器、主导智能体选举模块和共识涌现模块构成。当一个任务输入时，语义场域识别器首先分析其本质，确定其为“伦理决策”或“技术优化”等场域。随后，选举模块推举伦理 AGI 或规划 AGI 作为主导智能体。主导智能体召集相关 AGI 提交模式完形提案，并计算对齐度。当共识达成，主导智能体将最终决策转化为自然语言、代码或控制指令输出。

实施方式二：共识涌现

参阅图 2，详述对齐度计算与决策生成过程。本发明的一个具体实施例中，对齐度阈值 A_c 可设定为 0.7。权重 w_{ij} 的领域相关性部分，可通过计算任务描述与 AGI 标签库的 Sentence-BERT 向量余弦相似度来实现。

实施方式三：安全与韧性

框架审查 AGI 独立运行，持续计算所有流通提案与元价值向量的相似度。违宪阈值可设定为 0.2。一旦触发，审查 AGI 将向系统广播最高优先级的中断信号，并建议切换分析框架。