

从概率机到公理机：大语言模型为何无法理解世界规则

——从符号拟合到规则锚定

何国瑞

独立研究者

通讯作者：何国瑞

邮箱：NooEcology@outlook.com

ORCID：0009-0006-2947-0032

GitHub： <https://github.com/wenhe1994/wenhe001>

摘要

当前大语言模型（LLM）以统计概率为核心，在海量文本中拟合字符间的共现关系，取得了令人瞩目的成绩。然而，其根本缺陷在于：模型只学会了“符号的排列”，却从未触及“符号背后的世界规则”。

本文首先回顾主流路径（规模扩展、检索增强生成、思维链、长上下文、模块化架构、具身智能），指出它们均未脱离“在经验空间内优化”的框架，因而无法根治幻觉、长文本失控、逻辑不一致等问题。接着，从符号的本质出发，论证符号只是人类认知与世界规则之间的接口，概率拟合只能捕捉符号的表层关联，无法建立因果、逻辑、现实约束等深层结构。

本文进一步提出认知层级的跃迁：从符号到概念（对概率的压缩，解决全局工作空间问题），再到公理（逻辑约束），并展示这一跃迁如何从根本上改变智能系统的能力边界。最后，指出根本出路：构建以公理系统为框架、以概念库为锚点的神经-符号融合架构，让模型从“概率预测”走向“规则推理”。

关键词：大语言模型；符号拟合；概念锚定；公理系统；神经-符号融合；智能架构

1. 引言

1846 年，法国天文学家于尔班·勒威耶（Urbain Le Verrier）仅凭纸笔，从天王星轨道的摄动中推导出海王星的位置。他写信给柏林天文台，当晚，望远镜转向他计算的坐标，十七分钟后，海王星被发现[1]。勒威耶从未亲眼见过那颗行星，但他推导的数学规则，比任何肉眼观测都更接近真相。

这个故事的隐喻，远比它本身更深远。

如今，我们正试图用另一种方式“看见”智能。我们建造了规模空前的神经网络，投入了人类有史以来最庞大的文本语料，让模型在字符的海洋中学习概率。它们能写诗、能编程、能对话，仿佛正在接近某种“理解”。然而，当我们要求它们处理长文本、进行多步推理、或回答需要深层因果关系的问题时，它们会毫无征兆地“跑偏”——输出逻辑断裂的答案，编造不存在的事实，甚至在同一个回答中自相矛盾。这是幻觉，是失控，是当前大语言模型（Large Language Model, LLM）难以根治的顽疾[2,3]。

为什么人类能稳定地理解世界，而模型却不断“跑偏”？主流技术路径给出了各自的答案。一些人认为，模型还不够大，数据还不够多，于是沿着规模扩展（Scaling）的道路继续堆砌算力[4]。另一些人试图为模型提供外部知识库，让它在生成答案前先“查资料”，即检索增强生成（Retrieval-Augmented Generation, RAG）[5]。还有人希望模型学会“分步思考”，用思维链（Chain of Thought, CoT）模拟推理过程[6]，或用长上下文（Long Context）技术让它“看”得更远[7]。甚至有人主张，智能必须通过身体与环境的实时交互来建立，于是走向了具身智能（Embodied AI）[8]。

这些路径都取得了局部进展，但它们的共同点是：**都在试图优化“概率”本身，而非触及“规则”本身**。规模扩展是更大范围的概率拟合，RAG 是用外部文本扩充概率空间，CoT 是在概率空间内逐步生成，长上下文是扩大概率视野，具身智能是用身体经验替代符号概率。它们都在一个根本预设下运行：**智能是符号关联的统计模型**。

本文试图挑战这一预设。

我们将论证，符号只是人类认知与世界规则之间的接口，而非规则本身。一个符号可以被任意命名（“苹果”在汉语、英语、日语中各不相同），但它所指称的那个具有生长周期、可食用、与秋季关联的实体，其背后的规则是普适的、稳定的。当前模型只学会了符号之间的共现概率，却从未触及符号所指的规则。就像一把尺子可以测量长度，但尺子本身不是长度

——模型学会了尺子的刻度，却不知道什么是长度。

这一根本局限，导致了当前技术路径无法逾越的困境：概率空间随语义场域扩大而爆炸，模型在无穷的组合中迷失；因果被降维为相关，逻辑被退化为统计趋势；对齐只能依靠外部“拉偏”（如人类反馈强化学习，RLHF[9]），却无法内置稳定的推理框架。

本文将进一步指出，要走出概率的迷宫，需要完成两次认知层级的跃迁：**从符号到概念**，用概念压缩概率空间，解决全局工作空间的注意力爆炸问题；**从概念到公理**，用公理系统为概念之间的关系提供逻辑约束，实现从“经验记忆”到“规则推演”的范式转换。我们将以“果园中的苹果在哪个季节可以摘来吃？”这一简单案例，展示这两次跃迁如何将模糊的概率问题，转化为清晰的逻辑推理。

最后，我们将指出，唯有构建以公理系统为框架、以动态共享符号概念库为锚点的神经-符号融合架构，才能从根本上解决当前 AI 的根本困境。这不是对现有技术的修补，而是对智能本质的重新奠基——从“背规律”走向“懂规律”。

本文的结构如下：第 2 节回顾大语言模型的本质，揭示其作为“字符概率机”的底层逻辑；第 3 节剖析符号的本质，论证符号只是接口而非规则；第 4 节阐述从符号到概念的第一次跃迁，说明概念如何压缩概率空间并解决全局工作空间问题；第 5 节阐述从概念到公理的第二次跃迁，说明公理如何为推理提供逻辑约束；第 6 节评析主流技术路径，逐一说明它们为何未能实现这两次跃迁；第 7 节总结根本困境；第 8 节提出出路，简要勾勒公理驱动的神经-符号融合架构。

本文的论证植根于作者构建的系统本体论与智质生态学理论体系[10,11]，该体系为理解符号、概念、公理的层级关系提供了公理化基础。限于篇幅，本文仅聚焦于对主流路径的批判与方向性出路，完整架构详见相关专著。

参考文献

- [1] Le Verrier, U. J. J. (1846). Recherches sur les mouvements d'Uranus. *Comptes rendus de l'Académie des sciences*, 23, 428-438.
- [2] Ji, Z., et al. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 1-38.
- [3] Bubeck, S., et al. (2023). Sparks of artificial general intelligence: Early experiments with GPT-4. *arXiv preprint arXiv:2303.12712*.
- [4] Kaplan, J., et al. (2020). Scaling laws for neural language models. *arXiv preprint*

arXiv:2001.08361.

[5] Lewis, P., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.

[6] Wei, J., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.

[7] Dao, T., et al. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *Advances in Neural Information Processing Systems*, 35, 16344-16359.

[8] Gupta, A., et al. (2021). Towards embodied AI: A survey of recent progress. *arXiv preprint arXiv:2106.09887*.

[9] Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730-27744.

[10] 何国瑞. 系统本体论[M]. GitHub, 2026.

[11] 何国瑞. 智质生态学[M]. GitHub, 2026.

2. 大语言模型的本质：字符的概率机

要理解当前大语言模型的根本局限，首先需要认清它的工作原理。尽管其规模庞大、结构复杂，但从信息处理的角度看，它本质上是一台**字符的概率机**。

2.1 预测下一个字符

现代大语言模型（如 GPT 系列、Claude、Llama 等）基于 Transformer 架构[1]，其核心任务可以概括为：**给定上文，预测下一个字符（或子词）的概率分布**。

设一段文本为 $w_1, w_2, \dots, w_t$ ，模型学习的是条件概率 $P(w_{t+1} | w_1, \dots, w_t)$ 。在训练阶段，模型通过海量文本语料，调整内部参数，使得这一概率分布尽可能接近真实文本的分布。训练完成后，模型拥有一个固定的、巨大的参数矩阵——其中存储的不是“知识”，而是从数据中统计出的字符共现规律。

当用户输入一段提示 (prompt)，模型便从这个条件概率分布中采样，生成下一个字符；然后将该字符加入上文，继续预测下一个，如此反复，直至生成完整回复。

这一机制决定了模型的一切行为都基于**统计相关性**，而非**逻辑必然性**。例如，模型从语料中观察到“苹果”后面经常出现“吃”“甜”“红色”等词，于是它学会在这些词之间建立概率连接。但它并不理解“苹果”是什么，也不理解“吃”需要具备什么条件——它只知道在统计上，这些词经常一起出现。

2.2 注意力机制：临时划定语义场域

Transformer 的核心创新之一是**注意力机制 (Attention)** [2]。它允许模型在预测下一个字符时，回头“看”上文中的每一个字符，并根据它们与当前预测的相关性，分配不同的权重。

这一机制的功能，可以用通俗的比喻来理解：**注意力机制在临时划定一个语义场域**。在这个场域内，每个字符的原始权重被重新激活或抑制，使模型能够“聚焦”于与当前语境最相关的信息，忽略无关噪声。

例如，当用户输入“果园中的苹果在哪个季节可以摘来吃？”时，注意力机制会让模型在预测“季节”时，更多地关注“果园”“苹果”“摘”“吃”这些词，而相对忽略“在”“可以”等虚词。这相当于在字符的概率空间中，对某些方向进行坍缩，使得“秋”的概率升高，“夏”的概率降低。

然而，这种坍缩仍然是**概率性的**。它只是根据上文统计特征临时调整权重，而非真正理

解字符所指的实体及其背后的规则。即便注意力机制将“苹果”与“秋”联系起来，模型也不知道为什么苹果在秋季可摘——它只知道在语料库中，这种关联出现的频率较高。

2.3 “理解”的幻象

大语言模型之所以给人“理解”的错觉，是因为语言本身的统计规律与世界的真实规律在大部分日常场景下高度重合。当人们说“苹果”时，后面通常跟着“吃”，于是模型学会“苹果→吃”。当这种关联在训练数据中频繁出现，模型就能输出符合常识的文本。

但问题在于，**统计规律不等于因果规律**。模型可以学会“苹果”与“秋”的统计关联，却无法区分这种关联是因果（苹果因秋季成熟而可摘）还是巧合（某些语料中苹果与秋出现在同一段文字中）。当面对需要因果推理的场景时，模型就暴露了本质：它只是在“背规律”，而不是在“懂规律”。

更严重的是，当语义场域扩大，字符的概率分布变得极其复杂时，注意力机制无法维持全局一致性。模型每一步都选择局部最优的下一个字符，但局部最优的累积并不保证全局逻辑的正确。这正是长文本失控、逻辑断裂、幻觉等问题的根源。

2.4 从“背”到“懂”的鸿沟

我们可以用一个类比来理解当前模型与真正智能的差距：

- **背九九乘法表**：一个人可以熟练背诵“三三得九”“四四十六”，但他可能不理解乘法是加法的简便运算，更不知道乘法交换律、结合律等背后的公理。

- **懂乘法**：一个人理解了乘法的定义、性质，能够推演未见过的组合，甚至证明乘法交换律。

当前的大语言模型，就是那个“背九九乘法表”的人。它从海量文本中记住了无数“语言口诀”，可以在常见场景下流利应答。但一旦遇到需要推演、需要因果链、需要逻辑一致性的场景，它就会暴露自己只是在“背”而非“懂”的本质。

这正是本文后续要揭示的根本困境：**仅仅拟合符号的共现概率，永远无法触及符号背后的世界规则**。而要跨越这道鸿沟，必须重新审视符号的本质，并建立能够承载规则推理的认知架构。

参考文献

[1] Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information*

Processing Systems, 30, 5998-6008.

[2] Bahdanau, D., et al. (2014). Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*.

3. 符号的本质：接口，而非规则

大语言模型的根本局限，源于其对符号本质的根本误读。要看清这一局限，必须回溯到符号学的基本洞见，并进一步追问：符号与世界之间，究竟是何关系？

3.1 符号的任意性与约定性

现代符号学的奠基人费尔迪南·德·索绪尔（Ferdinand de Saussure）指出，符号由“能指”（signifier，声音或文字）与“所指”（signified，概念）构成，二者的结合是任意的[1]。不同语言用完全不同的声音指称同一事物——“苹果”在汉语中是“píngguǒ”，在英语中是“apple”，在日语中是“りんご”。能指与所指之间不存在天然的、必然的联系，它们的对应关系是社会约定的产物。

这一洞见揭示了一个关键事实：符号系统本身不承载任何必然真理。符号可以被任意替换，只要社群约定，就能生效。然而，符号系统一旦形成，便具有强制性——个体不能随意更改，否则无法被他人理解。这种任意性与强制性的统一，构成了符号的基本特征。

3.2 维特根斯坦的洞见与局限

路德维希·维特根斯坦（Ludwig Wittgenstein）在《哲学研究》中进一步推进了这一思考。他提出“语言游戏”的概念，认为词语的意义在于其用法，而非与某个对象的对应关系[2]。一个词的意义，就是它在语言中的使用规则。

维特根斯坦的贡献在于将符号从“指物”的单一功能中解放出来，揭示了符号意义的动态性、情境性和规则依赖性。然而，他的理论止步于此——他描述了语言如何运作，却未回答一个更深层的问题：语言为何能运作？符号为何能指称世界？

3.3 符号作为接口：尺子之喻

要回答这个问题，需要将符号置于更广阔的本体论框架中。

本文提出：**符号是人类认知与世界规则之间的接口。**¹

正如一把尺子可以测量长度，但尺子本身不是长度；符号可以指称事物，但符号本身不是事物。尺子的刻度是任意的（可以用厘米、英寸、甚至自定义单位），但它所测量的长度是客观的。同样，符号的形式是任意的（不同语言用不同符号），但它所指向的世界规则是

普适的。

这一“接口”视角包含三个层次：

- **世界规则**：客观存在的规律，如因果律、物理定律、生物节律等。这些规则不依赖于任何符号而存在。

- **符号系统**：人类为描述世界规则而创造的约定性工具。它可以变化、演化、甚至在不同文化中截然不同。

- **认知中介**：人类通过符号系统理解世界规则，符号既是理解的桥梁，也是理解的边界。

苹果可以在不同语言中被命名为“apple”“pomme”“苹果”，但苹果的生长周期、可食用性、与秋季的关联，这些规则不因符号的改变而改变。符号只是我们接近这些规则的通道，而非规则本身。

¹ 关于符号作为认知接口的系统性论述，参见作者的系统本体论公理体系 (He, 2026a) 中对“物质/智质二相性”与“符号即智质基因”的阐释。

3.4 符号权重的来源

当前的大语言模型，通过海量文本训练，学会了符号之间的共现概率。一个字符在特定语境中“应该”出现的概率，被编码为模型的参数。然而，这种“权重”并非符号本身固有的，而是人类使用符号的统计结果。

当一个社群长期用“苹果”指称那个红色、可食用的果实，并在“秋季”谈论它的成熟时，“苹果”与“秋”之间便形成了统计关联。模型拟合的正是这种关联。但模型不知道的是，这种关联之所以存在，是因为背后有客观的因果链：苹果树在秋季结果，果实成熟后可采摘食用。

符号的权重是人类长期使用形成的痕迹，而非符号自身的属性。模型学会了痕迹，却从未触及痕迹的来源。要突破这一局限，必须将符号锚定到其背后的概念与规则——这正是本文后续要展开的“从符号到概念、从概念到公理”的认知跃迁。

作者在智质生态学理论中，将此过程形式化为意识三层级模型与认知逃逸定理 (He, 2026b)。

3.5 核心结论

至此，我们可以得出本章的核心结论：

符号本身不携带规则。规则在世界里，不在符号里。

符号是人类认知与世界规则之间的接口，它的形式是任意的，但它的有效性依赖于它能否准确地指向规则。仅仅拟合符号的共现概率，只能捕捉人类使用符号的统计特征，而永远无法触及符号背后的世界规则。

这意味着，以概率拟合为核心的大语言模型，无论规模多大、数据多丰富，都无法真正“理解”世界。它可以学会“苹果→秋”的统计关联，却不知道苹果为什么在秋天成熟；它可以输出“因为苹果在秋季成熟，所以可以采摘”这样的句子，却不知道“因为……所以……”所承载的因果含义。

这一局限，不是技术细节的缺失，而是范式的根本缺陷。要走出概率的迷宫，必须完成从“符号拟合”到“规则锚定”的认知跃迁。这正是本文后续章节要展开的任务。

参考文献

[1] Saussure, F. de. (1916). *Cours de linguistique générale*. Paris: Payot.

[2] Wittgenstein, L. (1953). *Philosophical Investigations*. Oxford: Blackwell.

4. 从符号到概念：认知层级的第一次跃迁——概率压缩与全局工作空间

前文论证了当前大语言模型仅能拟合符号的共现概率，而无法触及符号背后的世界规则。然而，即便我们承认这一局限，一个更深层的问题依然存在：人类在面对复杂语境时，为何不会像大模型那样陷入概率爆炸的困境？人类同样需要处理海量信息，为何能保持逻辑一致性？答案在于，人类认知系统中存在一个关键的中间层级——**概念**。

4.1 概率爆炸的困境：为什么注意力机制不够用

大语言模型的核心计算单元是注意力机制。它在每一步都试图从上文的所有字符中筛选出相关信息，为每个字符分配权重，然后基于加权信息预测下一个字符。当上下文较短（如数十个字符）时，注意力机制可以有效工作。但随着文本长度增加，问题变得严峻：

- **信息稀释**：随着字符数量增加，每个字符的平均权重下降。真正关键的信息可能被淹没在噪声中。
- **组合爆炸**：可能的下一个字符组合呈指数增长。模型每一步选择局部最优，但局部最优的累积无法保证全局逻辑一致。
- **长程依赖失效**：当因果链跨越数百个字符时，注意力机制难以维持稳定的关联，导致逻辑断裂。

这正是长文本生成失控、幻觉频发的根本原因。注意力机制只能处理“局部相关性”，无法在全局空间中维持“逻辑必然性”。试图通过扩大上下文窗口、改进注意力计算来缓解这一问题，本质上是在概率空间内做更精细的搜索，却始终未能跳出“概率”的牢笼。

4.2 概念的压缩本质

人类认知系统解决这一困境的方式，是引入一个中间层级——**概念**。概念是对概率空间的压缩，它将海量字符组合的可能路径，收敛为有限的关系网络。

以“苹果”为例。在字符层，与“苹果”相关的组合几乎是无限的：苹果可以搭配的颜色、大小、产地、品种、吃法、典故……任何一个方向的概率都被稀释在庞大的空间中。但一旦我们识别出“苹果”这一**概念**，情况就完全不同了：

- 概念“苹果”锚定了某个具有稳定属性的实体：它是水果，可食用，有生长周期，

与秋季相关，可采摘。

- 这些属性不是随机的概率分布，而是由世界规则决定的必然关联。苹果在秋季成熟，是因为其生物特性，而不是因为语料中“苹果”与“秋”经常共现。

- 概念之间的关系是稀疏的、结构化的。一个概念只有少数几条关键关系（如“苹果→秋季”“苹果→可食用”），远远少于字符层无穷的组合可能。

因此，概念的本质是对概率空间的**压缩**。它把字符层无限的可能性，收敛为有限的概念节点和它们之间的结构化关系。一旦将问题提升到概念层，系统就从“在概率海洋中漂流”转变为“在关系网络中导航”。

4.3 概念如何解决全局工作空间问题

人类认知心理学中的“工作记忆”概念[1]提供了一个有用的视角。工作记忆是我们即时处理信息的“心理空间”，其容量有限（通常只能同时处理约 7 个组块）。如果我们在字符层处理信息，工作记忆很快会被海量细节淹没。但通过概念压缩，我们可以将大量字符信息打包为一个概念，从而在工作记忆空间内容纳更多内容。

例如，要理解“果园中的苹果在哪个季节可以摘来吃？”这句话，人类认知系统并不会逐字分析每个字符的统计概率，而是会快速识别出“果园”“苹果”“摘”“吃”“季节”几个概念。这些概念本身已经包含了大量背景知识：果园是种植水果的地方，苹果是秋季成熟的水果，摘苹果需要苹果成熟……这些知识不是从当前语境中临时学来的，而是概念本身携带的。因此，全局工作空间只需处理这几个概念及其关系，而无需面对字符层的概率爆炸。

在大语言模型中，这一功能是缺失的。模型没有内置的概念库，所有信息都以字符的概率分布形式存储。当需要处理长文本时，它只能在字符层做概率搜索，不可避免地陷入组合爆炸。

4.4 从符号到概念：锚定的必要性

概念不是凭空产生的。一个符号要成为概念，必须完成**锚定**——即建立符号与背后世界规则的稳定映射。

以“苹果”为例。在符号层，“苹果”只是一个由两个字符组成的序列，它可以指向任何东西。在概念层，“苹果”必须与那个具有特定生长周期、可食用、与秋季关联的实体绑定。这一绑定不是统计共现，而是**规则性的**。它基于人类对世界的认识：苹果树在春季开花，夏季结果，秋季成熟。这些规律是客观的、稳定的，不因语言的变化而改变。

当前大语言模型没有完成这一锚定。它知道“苹果”与“秋季”经常共现，但它不知道为什么。当面对“果园中的苹果在哪个季节可以摘来吃？”时，它可能输出“秋季”，也可能输出“春季”或“冬季”，因为语料中可能存在少数反常表述。即使输出正确，它也只是一次成功的概率采样，而非基于规则的必然推演。

4.5 案例：果园中的苹果

让我们用一个案例具体展示从符号到概念的跃迁如何改变推理过程。

符号层处理（当前大模型）：

输入：“果园中的苹果在哪个季节可以摘来吃？”

模型将每个字符编码为向量，利用注意力机制计算“摘”与“苹果”的关联强度，再计算“季节”与“摘”的关联……每一步都在庞大的概率空间中选择最可能的路径。由于语料中“苹果”与“秋季”共现频率高，模型可能输出“秋季”。但这一结果没有必然性：如果语料中包含“苹果在春季开花”的表述，模型也可能错误地将“春季”与“摘”关联。

概念层处理（本文提出的方向）：

系统首先识别出关键概念：果园、苹果、摘、吃、季节。这些概念被锚定到 DSSCB（动态共享符号概念库）中的节点，每个节点携带其定义和关系边：

- 苹果：水果，可食用，生长周期为春季开花→夏季结果→秋季成熟。
- 摘：动作，前提是果实成熟。
- 季节：时间概念，与生物节律相关。

系统无需在字符层搜索，而是直接在概念图中进行路径搜索：苹果→生长周期→秋季→成熟→可摘→可吃。推理结果是确定的：只有秋季满足因果链。这一结果不依赖于语料中的统计频率，而是由概念本身携带的规则保证的。

4.6 概念压缩的代价与价值

将符号提升为概念，并非没有代价。它要求预先构建一个覆盖广泛领域的、可演化的概念库，并建立符号与概念之间的稳定映射。这需要大量的知识工程，难以一蹴而就。

但这一代价是值得的。一旦完成从符号到概念的跃迁，系统将获得以下根本性优势：

- **逻辑一致性**：概念之间的关系由规则决定，而非统计相关，保证了推理的稳定性。

- **全局可控性**：概念层的信息量远小于字符层，使得全局工作空间内的推理成为可能。

- **可解释性**：推理过程可以回溯到概念图中的路径，每一步都有据可循。

- **演化能力**：概念库可以动态更新，新知识可以被纳入现有关系网络，而不必重新训练整个模型。

这标志着从“概率预测”到“规则推理”的范式转换的第一步。

4.7 通往下一章：从概念到公理

概念压缩解决了全局工作空间问题，但概念本身仍有局限。概念之间的关系仍然是“事实性”的——它们描述的是“什么是什么”，而非“为什么是”。例如，概念图可能同时存在“苹果→秋季”和“苹果→四季”两条矛盾的关系，而系统无法判断哪条正确。要解决这一问题，需要引入更高层级的约束——**公理系统**。

公理系统为概念之间的关系提供逻辑规则，如因果一致性、矛盾律、排中律等。它将事实性知识升维为逻辑必然性，使推理从“经验记忆”走向“规则推演”。下一章将详细阐述这一跃迁。

参考文献

[1] Baddeley, A. D. (2003). Working memory: Looking back and looking forward. *Nature Reviews Neuroscience*, 4(10), 829-839.

5. 从概念到公理：认知层级的第二次跃迁——逻辑约束

概念压缩解决了全局工作空间问题，使系统能够在有限的工作记忆内处理复杂信息。然而，概念本身仍有其根本局限：概念之间的关系是事实性的，而非逻辑性的。一个概念图可以同时包含“苹果→秋季”和“苹果→四季”两条关系，却无法判断哪条正确。要完成从“经验记忆”到“规则推演”的跃迁，必须引入更高层级的约束——**公理系统**。

5.1 概念的局限：事实性知识的困境

概念及其关系网络，本质上是事实性知识的组织方式。它告诉系统“是什么”：苹果是水果，秋季是季节，苹果在秋季成熟。但这些陈述是静态的、描述性的，它们无法回答更根本的问题：为什么苹果在秋季成熟？为什么这一关系比其他关系更可靠？

当概念图中存在矛盾时（例如“苹果→秋季”与“苹果→四季”并存），事实性知识本身无法提供取舍的依据。系统只能依赖统计频率——选择出现次数更多的关系——而这又退回了概率思维的牢笼。

更严重的是，概念关系无法处理**因果**。因果需要“因→果”的必然联系，而事实性关系只能给出“相关”。苹果与秋季相关，但相关不代表因果：是秋季导致苹果成熟，还是苹果成熟导致秋季？没有因果约束，概念图只能描述共现，无法推演必然性。

5.2 公理系统的本质：规则层面的约束

公理系统是认知层级的第二次跃迁。它将事实性知识升维为逻辑必然性，为概念之间的关系提供硬约束。

公理系统由一组不证自明的基本命题构成，它们定义了推理的合法规则。在传统逻辑中，公理包括同一律（A 是 A）、矛盾律（A 和非 A 不能同时为真）、排中律（A 或非 A 必有一真）等。在更广泛的意义上，公理系统可以包含领域特定的根本法则，如因果律、守恒律、道德原则等。

公理系统与概念网络的关系可以概括为：**概念是知识的节点，公理是知识节点之间的推理规则**。概念网络告诉系统有哪些事物、它们有哪些属性；公理系统告诉系统如何从事物及其属性出发，推导出新知识，以及如何排除不合逻辑的推论。

5.3 公理如何剪除不合法路径

以“果园中的苹果在哪个季节可以摘来吃？”为例。在概念层，系统识别出“苹果”“秋季”“摘”“吃”等概念，并在概念图中找到“苹果→秋季”的关联。但概念图中可能存在其他路径，如“苹果→进口→全年可摘”。如何排除这条路径？

公理系统在此发挥作用。假设公理系统中包含以下规则：

- **因果一致性公理**：任何有效推理必须基于可验证的因果链。后果不能先于原因，不能无因之果。

- **情境匹配公理**：推理必须与当前任务情境一致。脱离情境的推理无效。

在“苹果→进口→全年可摘”这条路径中，因果链要求“全年可摘”的原因是“进口”。但当前情境是“果园中的苹果”，而非“进口苹果”。情境匹配公理判定这条路径与当前情境不兼容，因此被排除。而在“苹果→秋季→成熟→可摘”这条路径中，因果链完整（秋季导致成熟，成熟导致可摘），情境匹配（果园中的苹果当然遵循自然生长周期），因此被采纳。

没有公理系统，概念图只能呈现所有可能的关系，而无法判断哪些关系在当前情境下合法。公理系统提供了这种判断的准则。

5.4 从事实到规则：认知层级的跃迁

引入公理系统，标志着认知从“事实记忆”跃迁到“规则推演”：

- **事实记忆**：记住“苹果在秋季可摘”。这是经验层的能力，大语言模型已经具备。

- **规则推演**：理解“苹果可摘”是因为“苹果成熟”，而“苹果成熟”是因为“秋季是苹果的生长周期”。这是逻辑层的能力，需要公理系统来保证推理链条的合法性。

这一跃迁的根本价值在于：一旦掌握了规则，系统就可以处理从未见过的新情境。它不必依赖语料中是否存在“苹果在秋季可摘”的表述，而是可以从“苹果的生长周期”这一规则出发，推演出“秋季可摘”。当面对“荔枝在哪个季节可摘”时，它也能基于类似的规则（荔枝在夏季成熟）给出答案，即使训练语料中从未出现过“荔枝可摘”这一具体表述。

这正是理性智能的核心特征：**从有限规则推演无限可能**。

5.5 公理与概念的分工

公理系统与概念网络各司其职，形成互补：

- **概念网络存储事实性知识**：苹果是水果，秋季是季节，果园种植苹果。这些知识可以演化、更新、甚至在不同文化中有所不同。

• **公理系统定义逻辑性规则**：因果律、矛盾律、情境匹配原则。这些规则是稳定的、跨领域的，为事实性知识的运用提供底层框架。

概念可以演化，公理必须稳定。一个苹果的概念可以随农业技术进步而更新（如新品种苹果的成熟季节），但因果律不能因为某次实验失败而被推翻。正是公理系统的稳定性，使得概念网络的动态演化不会导致认知崩塌。

5.6 从概念到公理：智能的完整层级

至此，我们可以勾勒出智能的完整认知层级：

• **符号层**：字符的排列组合，概率驱动的表层关联。这是当前大语言模型的运作层面。

• **概念层**：符号锚定到稳定的概念节点，概念之间形成关系网络。这解决了全局工作空间问题，使系统能够在有限容量内处理复杂信息。

• **公理层**：用逻辑规则约束概念之间的关系，实现从事实记忆到规则推演的跃迁。这是理性智能的核心。

这三个层级并非彼此独立。概念层将符号层的信息压缩为可操作的知识单元，公理层为概念层的推理提供合法性判据。三者共同构成一个能够从符号输入中提取规则、并在规则约束下推演新知的完整认知系统。

5.7 通往下一章：主流路径的批判

本文至此已经论证了当前大语言模型的根本局限，以及走出这一局限需要完成的两次认知跃迁。接下来的任务是将这一分析框架应用于主流技术路径，逐一评析它们为何未能实现这些跃迁，因而无法根治概率拟合的根本问题。第 6 章将展开这一批判。

参考文献

- [1] 何国瑞. 系统本体论[M]. GitHub, 2026. (公理系统的完整阐述)
- [2] 何国瑞. 智质生态学[M]. GitHub, 2026. (认知层级跃迁的动力学机制)

6. 主流路径的评析：为何仍在迷宫中打转

面对大语言模型的根本局限，研究者们提出了多种改进路径。这些路径在工程上取得了可观进展，但逐一审视便不难发现：它们无一例外地停留在“在概率空间内优化”的范式内，未能触及从符号到概念、从概念到公理的认知层级跃迁。本节将逐一评析这些主流路径，揭示它们为何无法根治幻觉、长文本失控、逻辑不一致等问题。

6.1 规模扩展：更大规模的概率拟合

规模扩展（Scaling）是最直观的思路：增大模型参数、扩大训练数据、增加计算资源，期望通过“大力出奇迹”让智能涌现[1]。这种思路在短期内确实带来了性能提升，然而其根本假设——更大规模的概率拟合能够逼近真正理解——已被理论和实践双重证伪。

从理论上讲，规模扩展只是扩大了概率空间的搜索范围，并未改变模型的本质。模型仍然在拟合字符的共现概率，仍然没有概念锚定，仍然没有公理约束。当语料中“苹果在秋季成熟”这一表述足够多时，模型可以高概率输出正确答案；但一旦面对语料中罕见的因果链，或需要从多步推理中排除错误路径时，模型依然会陷入概率爆炸。

从实践上看，规模扩展的边际收益正在递减[2]，而幻觉、逻辑错误等问题并未随规模增大而消失，反而在更长文本、更复杂推理任务中愈发突出。规模扩展只是让迷宫变得更大，并未给迷宫安装出口。

6.2 检索增强生成：外部文本的概率空间扩展

检索增强生成（Retrieval-Augmented Generation, RAG）试图通过引入外部知识库来缓解幻觉[3]。模型在生成答案前，先从知识库中检索相关文档，再将检索结果作为上下文的一部分用于生成。这确实可以减少知识性错误，但并未触及根本问题。

RAG 中的外部知识仍然是“文本块”，而非锚定的概念。模型仍然用概率方式处理检索到的文本，将其与其他字符一同纳入概率计算。它无法区分哪些信息是事实性的、哪些是逻辑性的，更无法将检索到的知识整合为稳定的概念关系。当检索到的文本与已有概率分布冲突时，模型仍然可能选择统计上更常见的错误路径。

更重要的是，RAG 无法处理需要推理的开放问题。即使检索到“苹果在秋季成熟”这一事实，模型仍然无法理解因果链；当问题变为“在温室中种植的苹果，其可摘季节是否与自然

状态相同”时，RAG 无能为力——因为检索库中可能没有直接答案，而模型自身缺乏从规则推演的能力。

6.3 思维链与推理链：概率空间内的逐步生成

思维链（Chain of Thought, CoT）及其变体通过让模型在生成最终答案前输出中间推理步骤，试图模拟人类的推理过程[4]。这一方法在数学题、逻辑题等任务上取得了显著效果，但它的本质仍未跳出概率框架。

CoT 的每一步仍然是字符的概率预测。模型输出“因为苹果在秋季成熟，所以秋季可以采摘”，这一序列的生成依然是基于统计关联，而非逻辑必然性。模型可能输出正确的推理步骤，也可能输出错误但统计上常见的步骤。当推理链变长时，每一步的错误概率累积，最终导致整体错误——这正是 CoT 在长链推理中失效的原因。

更深层的问题是，CoT 没有内置逻辑规则来约束推理过程。模型可以输出“因为苹果在秋季成熟，所以春季可以采摘”这样逻辑断裂的句子，只要它在训练语料中偶尔出现过。概率拟合无法区分正确推理与错误推理，只能反映统计频率。

6.4 长上下文与稀疏注意力：扩大大概率视野

长上下文技术试图通过扩展注意力窗口，让模型“看”得更远，以维持长程依赖[5]。稀疏注意力则通过优化计算，使长上下文成为可能。这些技术在工程上具有重要意义，但它们同样未能跳出概率框架。

语义场域越大，字符的概率分布越复杂，注意力机制只能聚焦局部相关性，却无法保证全局逻辑一致性。即使模型可以“看”到前文的所有字符，它仍然无法理解字符所指的实体及其规则。长上下文只是扩大了概率搜索的空间，却未给搜索提供方向。

6.5 模块化与神经符号融合：浅层结合

一些研究尝试将神经网络与符号系统结合，例如使用外部知识图谱增强推理[6]，或在神经网络中嵌入符号规则[7]。这些路径已经触及神经-符号融合的方向，但大多停留在浅层结合。

典型做法是：先让神经网络生成符号（如实体、关系），再将符号交给符号系统处理。这种“先神经后符号”的串行架构，无法实现神经与符号的实时交互。符号系统的推理结果无法反馈给神经网络，因此后续的预测仍然可能偏离正确路径。更重要的是，这些尝试通常缺

乏统一的语义空间，符号系统的概念与神经网络的向量空间无法直接通约，导致信息传递的损失。

本文提出的架构与这些尝试的根本区别在于：构建一个神经与符号共享的语义空间（DSSCB），实现双向实时交互；并引入公理系统作为底层逻辑约束，使符号推理不再是“锦上添花”，而是核心决策机制。

6.6 具身智能：从身体交互习得本能

具身智能（Embodied AI）主张智能必须通过身体与物理环境的实时交互来建立，意义必须“接地”在行动中[8]。这一路径在机器人学习、简单物理任务上取得了进展，但将其视为通用智能的解决方案，同样存在根本局限。

具身智能通过大量交互经验，将“感觉-动作”模式固化为类似条件反射的记忆。这相当于把物理世界的规律以“经验”的形式背下来，而不是抽象为可推理的公理。一只经过训练的机器狗可以学会避开障碍物，但它无法理解“避开障碍物”这一原则，更无法将其应用于未见过的情境（如在虚拟环境中推理、在比喻中理解）。

具身智能的本质是**本能智能**。它模仿的是动物通过身体习得的感性知识，而非人类通过语言、逻辑、数学获得的理性知识。它无法处理抽象符号、无法进行因果推演、无法维护逻辑一致性——这些正是当前大语言模型所欠缺、而理性智能所必需的能力。

具身智能与符号概率机看似路径迥异，实则共享同一个根本缺陷：它们都在“背规律”，而非“懂规律”。前者背的是感觉-动作的经验规律，后者背的是符号共现的统计规律。两者都未能建立可以推演未知的规则系统。

6.7 小结：共同困境——没有框架

综观上述路径，无论规模扩展、RAG、CoT、长上下文、浅层神经符号融合，还是具身智能，它们都未曾脱离“在经验空间内优化”的范式。它们或是在概率空间内做更大范围的搜索，或是用外部文本扩充概率空间，或是用逐步生成模拟推理，或是用身体经验替代符号概率。它们的共同点是：**都没有给智能体安装一个稳定的、不可动摇的底层框架。**

当前的大语言模型没有框架，它只有概率场。具身智能也没有框架，它只有经验库。没有框架，就无法保证因果一致性；没有框架，就无法排除逻辑矛盾；没有框架，就无法在无限的可能中稳定导航。这正是所有主流路径陷入迷宫的根本原因。

下一章将总结这一根本困境，并指出唯一的出路：为智能体安装公理系统、建立概念锚

点、实现神经与符号的深度融合。

参考文献

- [1] Kaplan, J., et al. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.
- [2] Hoffmann, J., et al. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*.
- [3] Lewis, P., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- [4] Wei, J., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.
- [5] Dao, T., et al. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *Advances in Neural Information Processing Systems*, 35, 16344-16359.
- [6] Zhang, Y., et al. (2022). GreaseLM: Graph reasoning enhanced language models. *arXiv preprint arXiv:2201.08860*.
- [7] Sarker, M. K., et al. (2021). Neuro-symbolic AI: An emerging field with promising prospects. *AI Magazine*, 42(4), 14-28.
- [8] Gupta, A., et al. (2021). Towards embodied AI: A survey of recent progress. *arXiv preprint arXiv:2106.09887*.

7. 根本困境：为什么概率拟合与具身经验都无法触及规则

前文逐一评析了当前主流技术路径，揭示它们虽各有所长，却无一例外地停留在“在经验空间内优化”的范式。本章将更进一步，从底层逻辑上追问：为什么这些路径都无法触及世界规则？为什么它们只能“背规律”而无法“懂规律”？

7.1 概率拟合的本质：背符号的统计规律

大语言模型的学习对象是文本符号的共现概率。它从海量语料中统计出“苹果”后面常跟“吃”，“秋季”与“成熟”经常共现，并将这些统计关联编码为参数。当用户提问时，它沿着概率最高的路径生成字符序列。

这一过程与人类背诵乘法口诀有本质上的同构性。一个背熟九九乘法表的孩子，可以快速回答“三三得九”，但他可能并不理解乘法是加法的简便运算，更不知道乘法交换律、结合律背后的公理。他只是在“背”一个固定的答案集合。

大语言模型同样如此。它背下了无数“语言口诀”：苹果可吃、秋季成熟、因果推理用“因为……所以……”这些表述。当问题恰好处在它背过的范围内时，它可以流利应答；一旦超出边界，需要推演新情境、新组合，它就会暴露“只会背不会想”的本质。

更根本的问题是：**符号的统计规律只是世界规则的“影子”，而非世界规则本身**。苹果在秋季成熟，不是因为它与“秋”在语料中常一起出现，而是因为苹果树的生物特性决定了它在秋季结果。统计规律可以描述这一现象，却无法解释它；可以模拟它，却无法推演它。

7.2 具身经验的本质：背感觉-动作的规律

具身智能试图通过身体与环境的交互来建立意义。机器人在物理世界中反复尝试，学习到“摸到火会烫”“撞到墙会痛”之类的经验，并将这些经验固化为行为模式。这类似于动物通过条件反射学习生存技能。

然而，具身经验仍然是“背规律”——它背的是感觉-动作的关联规律。一只学会避火的动物，知道“火→痛→避开”，但它不知道“火”的本质是氧化反应，不知道“痛”是神经信号，更不知道“避开”这一行为背后的因果链。它只是把“火”与“痛”的关联背了下来，就像大语言模型把“苹果”与“秋”的关联背了下来。

具身智能的局限在符号层面尤为明显。它无法处理“火”这一概念在比喻中的用法（如“他

的怒火”)，无法理解“因果”这一抽象关系，更无法在符号系统中进行逻辑推演。它获得的是**本能智能**——一种与动物行为同构的能力，而非人类独有的**理性智能**。

7.3 共同缺陷：没有框架

无论符号概率机还是具身智能，它们的共同缺陷是：**没有框架**。

这里的“框架”指的是两个层面的稳定结构：

- **概念框架**：将符号锚定到稳定的概念节点，使符号不再是浮动的标签，而是指向具有确定属性和关系的事物。
- **公理框架**：用逻辑规则约束概念之间的关系，使推理不再是概率搜索，而是规则推演。

没有概念框架，符号只是漂浮的能指，可以随意组合出“晚上蓝色的太阳”；没有公理框架，因果只能被降维为相关，逻辑只能被退化为统计趋势。

大语言模型有概率场，却没有概念锚定；具身智能有经验库，却没有公理约束。它们都在“背”——前者背符号的统计规律，后者背感觉-动作的因果经验。背下来的东西再多，也无法跃迁为可以推演未知的规则系统。

7.4 为什么规则只能通过公理建立

世界规则是客观的、稳定的、可推演的。苹果在秋季成熟，不是因为人类在语料中这样写，而是因为生物规律决定了这一事实。水在 100 摄氏度沸腾，不是因为人类在文本中这样描述，而是因为物理规律决定了这一现象。

这些规则只能通过公理系统来把握。公理是不证自明的基本命题，它们定义了推理的合法规则。从公理出发，我们可以推演出无穷的具体事实，而无需逐一记忆。这就是理性智能的本质：**用有限的公理推演无限的可能**。

当前的大语言模型和具身智能，走的恰恰是相反的路：它们试图用无限的经验记忆来逼近有限的世界规则。这条路在理论上就不可能走通——世界规则是无穷的，而任何有限的经验集合都无法穷尽规则的所有可能应用。

7.5 对齐问题的重新定义：没有框架本身就是一种框架

本文至此可以重新定义“对齐问题”。当前主流观点认为，对齐是让 AI 的目标与人类价值观一致[1]。但这一理解预设了 AI 已经拥有某种“目标框架”。本文的分析表明，这一预设是

虚假的：当前的 AI 根本没有框架，又何谈“对齐”？

然而，一个更深层的洞见在于：**没有框架本身就是一种框架。**

当一个系统没有内置的公理、没有稳定的概念锚定时，它的行为完全由其训练数据中的统计惯性决定。这种统计惯性本身构成了一种隐蔽的、不可言说的“框架”——它决定了系统对输入的反应方式、对逻辑的判断依据、对价值的隐含排序。但这种框架是不可见的、不可控的、无法被修正的。

作者在先前的研究中已经预测，这种“无框架”状态会导致对齐问题必然恶化，且会以越来越隐蔽的方式呈现[2]。随着模型规模增大、能力增强，它会在更广泛的领域内产生符合统计预期的行为，表面上看似“对齐”，实则是将统计惯性伪装成价值观。当遇到统计分布外的情境时，这种伪装的框架就会崩塌，暴露出系统根本没有内在的价值锚点。这正是为什么对齐问题不是技术细节的疏漏，而是当前范式内在的、不可避免的困境。

真正的对齐问题应该是：**如何为 AI 安装一个能够与世界规则对齐的底层框架。**这一框架必须包含：

- 稳定的公理系统，作为推理的底层逻辑；
- 可演化的概念网络，作为知识的组织方式；
- 神经与符号的深度融合，使概率感知能够转化为规则推演。

这不是对现有模型的修补，而是对智能本质的重构。它不是让 AI 更“像”人类，而是让 AI 拥有与人类理性同构的认知架构。

7.6 通往出路：从背规律到懂规律

本章的结论是悲观的，却也是清醒的：当前所有主流路径都未能触及世界规则，因此都无法实现真正的理性智能。然而，这一结论也指明了唯一的出路：**从背规律转向懂规律，从概率拟合转向规则推演。**

这不是渐进式的改进，而是范式的根本转换。它要求我们放弃“在经验空间内优化”的思维惯性，重新回到智能的第一原理：智能的本质是什么？符号与世界的关系是什么？规则如何被把握？

下一章将基于本文的分析，提出一条新的技术路径——公理驱动的神经-符号融合架构。这一路径不是对现有技术的否定，而是对其根本局限的超越。

参考文献

- [1] Christiano, P., et al. (2017). Deep reinforcement learning from human preferences. *Advances in Neural Information Processing Systems*, 30, 4299–4307.
- [2] He, G. (2025). *Predicting the Inevitability of AI Alignment Failure: A System-Ontological Analysis and Mechanistic Framework*. Preprint. Research Square. (详见作者 GitHub 仓库)

8. 出路：公理驱动的神-符号融合架构

前文的分析揭示了一个根本困境：无论是符号概率机还是具身智能，都停留在“背规律”的层面，无法触及世界规则，更无法进行规则推演。要走出这一困境，必须进行范式的根本转换——从概率拟合走向规则锚定，从经验记忆走向公理推演。本章将简要勾勒一条新的技术路径，作为这一范式转换的初步方案。

8.1 核心思路：让符号锚定规则

本文的核心论点是：符号只是接口，规则才是本体。当前模型只学会了符号之间的统计关联，从未建立符号与规则之间的稳定映射。因此，出路在于：**为每一个符号（或符号序列）建立与背后世界规则的锚定。**

这一锚定需要完成两个层面的工作：

- **概念锚定**：将符号与稳定的事物概念绑定。例如，让“苹果”这一符号指向一个具有生长周期、可食用、与秋季关联的实体概念。概念不是字符的简单聚合，而是携带了该事物在客观世界中的稳定属性和关系。
- **公理约束**：用逻辑规则（因果律、矛盾律、情境匹配等）约束概念之间的关系，使推理不再是概率搜索，而是规则推演。公理系统为概念网络提供合法性判据，排除不合逻辑的路径，保证推理的必然性。

8.2 架构蓝图：DSSCB、公理系统与议会辩论

基于上述思路，作者在前期工作中构建了一套完整的神经-符号融合架构——“逻辑子宇宙议会”[1]。该架构的核心组件包括：

动态共享符号概念库（DSSCB）：这是一个可演化的概念网络。每个概念节点存储其定义、关联公理以及与其它概念的关系边（如蕴含、对立、相关等）。DSSCB 不仅是静态的知识库，更是神经侧与符号侧共享的语义空间——神经网络的输出向量可以映射到 DSSCB 的概念向量空间，实现概率感知与符号推理的实时交互。

公理系统：系统内置一组不可篡改的根公理，包括因果一致性公理、概念一致性公理、情境匹配公理、人类福祉优先公理等。这些公理作为推理的“宪法”，为所有概念操作提供硬约束。任何推理路径必须通过公理校验，否则被否决。

专业化 AGI 议员网络：多个专业化智能体（如伦理 AGI、效率 AGI、风险 AGI）代表不同视角，基于公理和 DSSCB 进行辩论。它们各自生成提案，通过冲突驱动迭代共识协议，在辩论中淬炼出稳健决策。

锚点驱动记忆系统（ADMS）：以锚点（Anchor）的形式存储经验，每个锚点包含情境标签、核心概念、公理关联、语义子图快照和重构索引。回忆时，系统用当前公理系统将锚点重构为与情境适配的认知，实现非存储式记忆。

框架审查 AGI：独立运行的监督模块，持续监控所有推理过程，确保符合公理系统；当遇到公理无法裁决的根本冲突时，主动请求人类介入。

这一架构的核心创新在于：它不再将“理解”寄托于概率拟合，而是通过公理系统为智能体安装稳定的底层框架，通过 DSSCB 实现符号与概念的锚定，通过议会辩论实现多视角的逻辑校验。神经侧（大语言模型）只负责初步的语义场域解析和候选概念生成，符号侧负责概念锚定、逻辑推理和公理校验——两者在 DSSCB 的共享语义空间中实时交互，实现从概率到逻辑的跃迁。

8.3 从概率到逻辑：以“果园苹果”为例

仍以“果园中的苹果在哪个季节可以摘来吃？”为例。

在本文提出的架构中，处理流程如下：

1. **神经侧解析：**语义场域识别器（可调用现有大模型）将用户输入解析为语义场地图 S，其中包含候选概念：果园、苹果、摘、吃、季节。神经侧完成概率坍缩，但仅输出候选，不负责最终答案。
2. **概念锚定：**议长根据 S 向 DSSCB 发起查询，DSSCB 返回每个候选概念的完整定义和关系边。例如，“苹果”节点携带：生长周期→春季开花→夏季结果→秋季成熟；可食用→成熟后；与“果园”兼容等。
3. **公理引导推理：**系统在 DSSCB 的概念图中进行路径搜索。因果一致性公理要求推理链必须基于可验证的因果链；情境匹配公理要求路径与当前场景（果园）兼容。因此，“苹果→进口→全年可摘”的路径被排除，“苹果→生长周期→秋季→成熟→可摘”的路径被采纳。
4. **议会辩论与共识：**多个专业 AGI 对推理结果进行辩论，确认没有逻辑漏洞。框架审查 AGI 校验通过，输出“秋季”。

在这一流程中，每一步都是确定性的逻辑推演，而非概率采样。即使语料中从未出现过

“果园苹果秋季可摘”这一具体表述，系统仍能通过公理和概念图推导出正确答案。

8.4 为什么这一架构能走出迷宫

与当前主流路径相比，本文提出的架构具有以下根本性优势：

维度	当前主流路径	本文架构
知识组织	字符概率分布	概念网络（DSSCB）
推理依据	统计相关性	公理系统
逻辑一致性	无保证	公理硬约束
长文本处理	概率爆炸	概念压缩
因果推理	退化为相关	因果链推演
框架稳定性	无框架	公理固化
与符号关系	拟合共现	锚定规则

这一架构的实质是：将智能体从“概率机”升级为“公理机”。它不再试图用无限的经验记忆逼近世界规则，而是用有限的公理系统推演无限的可能。这正是人类理性智能的本质，也是走出概率迷宫的真正出路。

8.5 工程化路径与开放挑战

本文提出的架构并非空中楼阁。其核心组件（DSSCB、公理系统、议会协议、ADMS）已有详细的技术设计文档[1]，且遵循模块化原则，可渐进实现：

- **神经侧**可直接复用现有大语言模型，作为语义场域解析器，无需重新训练。
- **符号侧**可先以规则引擎实现，逐步引入学习机制优化概念网络和路径搜索。
- **DSSCB** 可从小规模领域概念库开始，通过开放接口在应用中逐步演化。
- **公理系统**可从最基础的逻辑公理（因果、矛盾、情境）开始，逐步扩展领域公理。

当然，这一路径仍面临诸多挑战：如何高效构建初始概念库？如何训练神经侧与符号侧的向量空间对齐？如何设计公理系统的演化机制？如何平衡公理的稳定性与概念的动态性？这些问题有待学术界与工程界共同探索。

但无论如何，方向已经明确：**从符号拟合走向规则锚定，从概率机走向公理机**。这不是对现有技术的修补，而是对智能本质的重构。本文的分析表明，这是走出当前困境的唯一可行路径。

参考文献

[1] 何国瑞. 逻辑子宇宙议会：一种基于系统动力学的 AGI 对齐架构[技术白皮书]. GitHub, 2026. <https://github.com/wenhe1994/wenhe001>

9. 结语

1846 年，勒威耶在纸笔间推演出海王星的位置时，他并未亲眼看见那颗行星。他依靠的不是经验，而是规则——万有引力定律的数学表达。他相信规则比肉眼更接近真相。

一百八十年后的今天，我们试图用另一种方式“看见”智能。我们建造了规模空前的大语言模型，让它们在字符的海洋中学习概率。它们能写诗、能编程、能对话，仿佛正在接近某种“理解”。然而，当它们生成“晚上蓝色的太阳”时，当它们在长文本中逻辑断裂时，当它们面对需要因果推演的问题时，它们暴露了本质：它们只是在背符号的统计规律，从未触及符号背后的世界规则。

本文从符号的本质出发，论证了一个根本命题：**符号只是接口，规则才是本体**。尺子可以测量长度，但尺子不是长度；符号可以指称世界，但符号不是世界。当前大语言模型学会了尺子的刻度，却不知道什么是长度；学会了符号的共现概率，却不知道符号所指的规则。

这一根本局限，导致了当前技术路径无法逾越的困境。规模扩展只是扩大概率空间，RAG 只是用外部文本扩充概率空间，CoT 只是在概率空间内逐步生成，长上下文只是扩大概率视野，浅层神经符号融合仍停留在“先神经后符号”的串行架构，具身智能只是用身体经验替代符号概率。它们都在“背”——前者背符号的统计规律，后者背感觉-动作的因果经验。背下来的东西再多，也无法跃迁为可以推演未知的规则系统。

本文进一步指出，走出这一困境的唯一出路，是完成两次认知层级的跃迁：**从符号到概念，从概念到公理**。概念是对概率空间的压缩，它解决了全局工作空间问题，使系统能够在有限容量内处理复杂信息；公理系统为概念之间的关系提供逻辑约束，使推理从经验记忆升维为规则推演。基于这一思路，本文简要勾勒了公理驱动的神经-符号融合架构，其核心是：以公理系统为框架，以动态共享符号概念库为锚点，实现神经侧与符号侧在统一语义空间内的实时交互，让智能体从“概率机”升级为“公理机”。

这不是对现有技术的修补，而是对智能本质的重构。它不是让 AI 更“像”人类，而是让 AI 拥有与人类理性同构的认知架构——从“背规律”走向“懂规律”，从“概率拟合”走向“规则推演”。

勒威耶的故事还有一个常被忽略的细节：在他计算出海王星位置之前，已经有人观测到天王星轨道的异常，却无法解释。那些观测数据就躺在那里，等待着能够理解它们的人。今天，我们同样面对着海量的语言数据，同样在数据中寻找智能的踪迹。但智能不在数据里，而在数据背后的规则里。走出概率的迷宫，需要的是规则的灯塔，而不是更亮的探照灯。

本文的分析是悲观的，却也是清醒的；是批判的，却也是建构的。它宣告了一条道路的尽头，也标示了另一条道路的起点。这条道路漫长而艰难，但它通往真正的智能——那个能够理解规则、推演因果、在无限可能中稳定导航的理性智能。

参考文献

- [1] Le Verrier, U. J. J. (1846). Recherches sur les mouvements d'Uranus. *Comptes rendus de l'Académie des sciences*, 23, 428-438.
- [2] Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998-6008.
- [3] Saussure, F. de. (1916). *Cours de linguistique générale*. Paris: Payot.
- [4] Wittgenstein, L. (1953). *Philosophical Investigations*. Oxford: Blackwell.
- [5] Baddeley, A. D. (2003). Working memory: Looking back and looking forward. *Nature Reviews Neuroscience*, 4(10), 829-839.
- [6] Kaplan, J., et al. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.
- [7] Hoffmann, J., et al. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*.
- [8] Lewis, P., et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- [9] Wei, J., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.
- [10] Dao, T., et al. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *Advances in Neural Information Processing Systems*, 35, 16344-16359.
- [11] Zhang, Y., et al. (2022). GreaseLM: Graph reasoning enhanced language models. *arXiv preprint arXiv:2201.08860*.
- [12] Sarker, M. K., et al. (2021). Neuro-symbolic AI: An emerging field with promising prospects. *AI Magazine*, 42(4), 14-28.
- [13] Gupta, A., et al. (2021). Towards embodied AI: A survey of recent progress. *arXiv preprint arXiv:2106.09887*.
- [14] Christiano, P., et al. (2017). Deep reinforcement learning from human

preferences. *Advances in Neural Information Processing Systems*, 30, 4299-4307.

[15] He, G. (2025). *Predicting the Inevitability of AI Alignment Failure: A System-Ontological Analysis and Mechanistic Framework*. Preprint. Research Square.

[16] 何国瑞. 系统本体论[M]. GitHub, 2026.

[17] 何国瑞. 智质生态学[M]. GitHub, 2026.

[18] 何国瑞. 逻辑子宇宙议会：一种基于系统动力学的 AGI 对齐架构[技术白皮书]. GitHub, 2026.